

Biometria — Projekt 3

Uwierzytelnianie twarzy *in-the-wild*:
odporność na niską rozdzielczość (CCTV) oraz wiele twarzy na obrazie

Dane autorów

Autorzy: [Imię Nazwisko, nr indeksu]
[Imię Nazwisko, nr indeksu]
[Imię Nazwisko, nr indeksu]
Termin laboratorium: [dzień, godzina, grupa]

1 Opis problemu

Celem projektu jest system **uwierzytelniania na podstawie obrazu twarzy**, który zachowuje skuteczność na *trudnych* próbkach pobieranych bez kontroli nad otoczeniem (*in-the-wild*). Zgodnie z poleceniem wybraliśmy dwa utrudnienia:

#3 Bardzo niska rozdzielczość / jakość — twarze wielkości kilkudziesięciu pikseli, jak z kamer CCTV (scenariusz zbioru TinyFace).

#1 Wiele twarzy na zdjęciu — na obrazie widocznych jest kilka osób; system musi wybrać właściwą do uwierzytelnienia.

Zgodnie z dopuszczeniem w poleceniu **korzystamy z gotowego, wstępnie wytrenowanego modelu i nie dotrenowujemy go**. Odporność na trudne dane budujemy wyłącznie *trikami na etapie wnioskowania* (ang. *test-time*). Cel ilościowy: na próbkach trudnych współczynnik FRR nie powinien wzrosnąć o więcej niż 5 punktów procentowych (pp), a True Identification Rate nie powinien spaść o więcej niż 5 pp względem próbek czystych, przy minimalizacji FAR.

Wykorzystane źródła i narzędzia.

- **ArcFace** (Deng i in., 2019) — funkcja straty i architektura sieci do rozpoznawania twarzy; użyty backbone `iresnet50`, wagi `ms1mv3_arcface_r50` (trenowane na zbiorze MS1MV3).
- **InsightFace** (model detekcji `buffalo_1`) — detekcja twarzy i punktów charakterystycznych oraz wyrównanie (*alignment*).
- Zbiory bazowe: **FaceCard** (LFW-podobny), zdjęcia własne członków grupy.
- Scenariusz niskiej rozdzielczości inspirowany zbiorem **TinyFace**.

2 Metoda uwierzytelniania

2.1 Zasada działania

Sieć ArcFace zamienia wyrównany obraz twarzy (112×112 px) na **embedding** — wektor 512 liczb będący „odciskiem palca” twarzy. Embeddingi tej samej osoby są do siebie zbliżone, różnych osób — odległe. Podobieństwo mierzymy **dystansem kosinusowym** $d = 1 - \cos(\theta)$ (mały dystans = ta sama osoba). System działa w dwóch trybach:

- **Weryfikacja (1:1)** — porównanie próbki z galerią jednej deklarowanej osoby; decyzja: akceptacja gdy $d \leq \text{próg}$.
- **Identyfikacja (1:N)** — porównanie z galeriami wszystkich wdrożonych osób i wybór najbliższej (Top-1), z opcją odrzucenia (*open-set*).

2.2 Pipeline i modyfikacje uodparniające

Każda próbka przechodzi przez łańcuch (rysunek koncepcyjny poniżej); pogrubione kroki to nasze modyfikacje wprowadzone dla odporności:

obraz → **detekcja odporna (padding)** → **selekcja właściwej twarzy (#1)** → ocena jakości **FIQA (#3)** → **restauracja warunkowa (#3)** → wyrównanie 112^2 → embedding + **TTA** → dopasowanie (galeria wielowzorcowa, **próg adaptacyjny**)

Detekcja odporna na ciasne kadry (kluczowa modyfikacja).

Zdjęcia FaceCard oraz kadry CCTV to *ciasne wycięcia* — twarz wypełnia cały obraz bez marginesu, przez co detektor jej *nie wykrywa*. Bez detekcji następuje awaryjne wycięcie środka (*center-crop*) **bez wyrównania**, co drastycznie psuje rozpoznawanie. Nasze rozwiązanie: gdy detekcja na surowym obrazie zawiedzie, dokładamy margines (replikacja brzegu) i ponawiamy detekcję. To umożliwia poprawne wyrównanie. Modyfikacja podniosła skuteczność na niskiej rozdzielczości z $\sim 0\%$ do $\sim 55\%$ (sama detekcja), a z pozostałymi trikami do 77% .

Selekcja właściwej twarzy (#1).

Spośród wszystkich wykrytych twarzy wybieramy kandydata na podstawie wielkości, centralności i pewności detekcji; przypadki niejednoznaczne odrzucamy.

Ocena jakości twarzy — FIQA (#3).

Liczbowa ocena jakości próbki (ostrość, rozmiar twarzy), sterująca restauracją i progiem adaptacyjnym.

Restauracja warunkowa (#3).

Dla próbek o niskiej jakości stosujemy poprawę obrazu przed rozpoznaniem.

Test-Time Augmentation (TTA).

Embedding liczony dla kilku wariantów obrazu (m.in. odbicie lustrzane) i uśredniany — stabilniejszy wynik.

Galeria wielowzorcowa.

Na osobę przechowujemy kilka embeddingów; próbkę porównujemy do najbliższego z nich.

Próg adaptacyjny.

Dla próbek o niskiej jakości próg decyzji jest delikatnie luzowany.

2.3 Próg decyzji

Próg dobieramy **automatycznie** na zbiorze czystym tak, aby FAR wynosił 1% (zgodnie z celem „minimalizować FAR”). Otrzymany próg operacyjny to dystans $d^* = 0,7735$, co odpowiada podobieństwu kosinusowemu $\cos \theta \approx 0,23$. Próg adaptacyjny luzuje go do $\cos \theta \approx 0,15$ dla najgorszej jakości.

3 Zbiór danych, podział i subsampling

3.1 Źródła i podział na role

Podział tożsamości jest **deterministyczny** (ziarno losowości = 42, pełna powtarzalność) i **rozłączny** — żadna osoba nie występuje w dwóch rolach, co zapobiega zawyżaniu wyników. Uwzględniamy tylko tożsamości mające ≥ 4 zdjęcia.

Rola	Liczba osób	Zastosowanie (etap)
enrolled (wdrożeni)	100	wzorce w bazie; <i>w tym cała grupa</i> (etap wdrożenia)
impostors (impostorzy)	120	próbki „obcych” do odrzucenia (etap testu)
distractors (dystraktory)	150	dodatkowe twarze w scenach #1 (generacja danych)

Tablica 1: Podział tożsamości na role. Osoby wdrożone i impostorzy są rozłączni.

3.2 Procedura wdrożenia (enrollment)

Dla każdej z 100 wdrożonych osób bierzemy **3 pierwsze czyste zdjęcia** i zapisujemy **3 osobne embeddingi** (galeria wielowzorcowa — nie uśredniamy). Zdjęcia użyte do wdrożenia są wykluczone z testu.

3.3 Tworzenie zbiorów testowych

Wszystkie próbki trudne powstają z *czystych* zdjęć osób wdrożonych, dzięki czemu mamy **pary** czyste $\leftrightarrow$ trudne tej samej osoby i możemy mierzyć degradację wprost.

Zbiór czysty (clean) — 1103 próbki.

983 próbki *genuine* (zdjęcia osób wdrożonych nieużyte do wdrożenia, do 10 na osobę) + 120 próbek *impostor* (po 1 zdjęciu każdej osoby niewdrożonej). Punkt odniesienia.

Zbiór trudny #3 (lowres) — 2949 próbek.


Z każdego czystego zdjęcia *genuine* generujemy 3 warianty degradacji CCTV: zmniejszenie twarzy do **20–40 px**, opcjonalne rozmycie i szum, kompresja JPEG (jakość 35–65), powiększenie z powrotem do 112 px.

Zbiór trudny #1 (multiface) — 2949 próbek.

Z każdego czystego zdjęcia *genuine* budujemy scenę 512×512 px zawierającą twarz właściwej osoby oraz **1–3 twarze dystraktorów**.

Zbiór	Próbki	w tym genuine	w tym impostor	Etap
clean	1103	983	120	odniesienie
lowres (#3)	2949	2949	—	test trudny
multiface (#1)	2949	2949	—	test trudny
razem	7001			

Tablica 2: Liczności zbiorów. Trudnych łącznie 5898 (wymóg ≥ 5000 , zbalansowane $\approx 50/50$); czystych 1103 (wymóg ≥ 1000).



Rysunek 1: Po lewej: rozmiary zbiorów testowych. Po prawej: ta sama osoba w wariancie czystym, niskiej rozdzielczości (#3) i wielu twarzy (#1).

4 Procedura uwierzytelniania i testowania

4.1 Uwierzytelnianie

Próbka przechodzi przez opisany pipeline, otrzymujemy jej embedding, liczymy dystans kosinusowy do galerii i podejmujemy decyzję (weryfikacja: $d \leq \text{próg}$; identyfikacja: najbliższa galeria, z opcją odrzucenia). Przetwarzanie jednej próbki trwa ułamek sekundy (wymóg < 30 s spełniony).

4.2 Metryki

- **FRR** (False Rejection Rate) — odsetek osób prawdziwych błędnie odrzuconych.
- **FAR** (False Acceptance Rate) — odsetek impostorów błędnie zaakceptowanych.
- **TIR** (True Identification Rate) — odsetek poprawnych identyfikacji Top-1 (oraz Top-5).
- **EER** (Equal Error Rate) — punkt, w którym FAR=FRR (im mniej, tym lepiej).

4.3 Prace nad korektą wyników na próbkach zaburzonych

W trakcie ewaluacji zidentyfikowaliśmy i naprawiliśmy dwa kluczowe problemy:

1. **Brak wyrównania na ciasnych kadrach** — detekcja zawodziła na 100% próbek lowres; wprowadzenie *detekcji odpornej z paddingiem* podniosło TIR z 0% do $\sim 77\%$.
2. **Niestabilny dobór progu** — pierwotny próg z punktu EER na zbiorze idealnie rozdzielonym był nieokreślony; zastąpiliśmy go progiem przy zadanym FAR=1%.


5 Wyniki

Utrudnienie	EER	FRR	FAR	TIR@1	TIR@5
clean	0,57%	0,41%	1,24%	99,59%	99,79%
#1 multiface	0,59%	0,44%	1,22%	99,56%	99,66%
#3 lowres	10,62%	17,24%	2,62%	77,37%	87,48%


Tablica 3: Wyniki pełnego systemu (próg $d^* = 0,7735$, AUC na clean = 0,999).

Utrudnienie	ΔFRR	$\Delta\text{TIR@1}$	Cel ≤ 5 pp
#1 multiface	+0,03 pp	-0,03 pp	spełniony
#3 lowres	+16,83 pp	-22,21 pp	niespełniony


Tablica 4: Degradacja względem zbioru czystego. Multiface mieści się w celu; lowres przekracza go o ~ 17 pp (TIR) / ~ 12 pp (FRR).



Rysunek 2: Po lewej: krzywe ROC (weryfikacja). Po prawej: True Identification Rate.



Rysunek 3: FAR i FRR w funkcji progu dla każdego utrudnienia (linia przerywana — próg operacyjny). Dla lowres rozkłady genuine i impostor zachodzą na siebie, stąd kompromis.




Rysunek 4: Rozkłady dystansów genuine (zielony) vs impostor (czerwony). Dla clean i multiface istnieje wyraźna przerwa; dla lowres rozkłady się nakładają — to obrazuje twardy limit rozpoznawania twarzy niskiej rozdzielczości.

5.1 Ablacja — wkład trików

Porównujemy pełny system z wariantem bazowym (bez selekcji, restauracji, TTA i progu adaptacyjnego).

Utrudnienie	TIR@1 <i>bazowy</i>	TIR@1 <i>pełny</i>	FRR <i>bazowy</i>	FRR <i>pełny</i>
clean	99,59%	99,59%	0,51%	0,41%
#1 multiface	14,72%	99,56%	85,42%	0,44%
#3 lowres	55,68%	77,37%	45,30%	17,24%

Tablica 5: Ablacja. Dla #1 całą skuteczność daje *selekcja twarzy* (14,7%→99,6%); dla #3 restauracja + TTA dokładają +21,7 pp.



Rysunek 5: Ablacja: wariant bazowy vs pełny system (FRR i TIR Top-1).

5.2 Porównanie z modelem bazowym i literaturą

Na próbkach **czystych** (wysoka rozdzielczość) nasz system osiąga $\text{TIR@1} = 99,6\%$ — zgodnie z poziomem raportowanym przez autorów ArcFace dla danych frontalnych dobrej jakości ($\sim 99,8\%$ na LFW). Potwierdza to, że pipeline nie wprowadza degradacji w warunkach nominalnych.

Dla **niskiej rozdzielczości** nasz wynik 77% rank-1 (na syntetycznej degradacji 20–40 px) jest na poziomie lub powyżej typowych wyników gotowych modeli rozpoznawania twarzy raportowanych na zbiorze TinyFace (rzęd $\sim 30\text{--}60\%$ rank-1 dla modeli „z półki”, $\sim 60\text{--}70\%$ dla metod dedykowanych niskiej rozdzielczości). *Uwaga:* porównanie jest poglądowe — nasza degradacja jest syntetyczna i protokół nie jest identyczny z TinyFace, więc liczb nie należy zestawiać wprost.

6 Wnioski

- **Utrudnienie #1 (wiele twarzy) — cel w pełni osiągnięty** ($\Delta\text{TIR} = -0,03$ pp). Ablacja pokazuje, że decydująca jest *selekcja właściwej twarzy*: bez niej system wybiera przypadkową twarz i skuteczność spada do 14,7%. Problem ma więc charakter „logiczny” (wybór celu), a nie utraty informacji, i daje się rozwiązać trikiem test-time.
- **Utrudnienie #3 (niska rozdzielczość) — cel niespełniony** ($\Delta\text{TIR} = -22,2$ pp, $\Delta\text{FRR} = +16,8$ pp). Mimo to triki dały duży zysk: od $\sim 0\%$ (bez wyrównania) przez 55% (sama detekcja odporna) do 77% (pełny system). Pozostała luka to **twardy limit** — przy twarzy 20–40 px sieć fizycznie traci część informacji o tożsamości, czego nie odzyska się bez dotrenowania modelu lub ciężkiej restauracji generatywnej (np. GFPGAN/CodeFormer).
- **Najważniejsza modyfikacja** to detekcja odporna na ciasne kadry — pojedyncza zmiana decydująca o sensowności wyników na obu utrudnieniach.

- **Kierunki dalsze:** (i) generatywna restauracja twarzy dla lowres; (ii) dotrenowanie/„low-resolution aware” fine-tuning backbone; (iii) krzywa TIR vs rozdzielczość twarzy w celu wyznaczenia progu, od którego cel ≤ 5 pp jest osiągany.